Contents

科技金融日报 | Tech-Finance Daily **1**
今日导读 . . . 1
全球 AI 动态 . . . 1
1. 银行业 AI 应用进入”价值创造”阶段 . . . 1
2. 2025 年银行业 AI 十大典型应用案例 . . . 1
技术架构深度 . . . 2
3. DeepSeek 系列：高效 LLM 训练的工程范式 . . . 2
4. AI Agent 在金融领域的落地实践 . . . 3
数据洞察 . . . 4
5. 2025 年普惠金融 AI 规模化成效 . . . 4
监管与政策 . . . 4
6. 监管层面的 AI 推进信号 . . . 4
深度观点 . . . 4
7. 银行业 AI 发展的三个关键判断 . . . 4
延伸阅读 . . . 4
明日关注 . . . 4

科技金融日报 | Tech-Finance Daily

2026 年 3 月 24 日 星期二 | Asia/Shanghai

今日导读

本期聚焦：**银行业 AI 规模化应用元年 | DeepSeek 效率架构深度解析 | AI Agent 金融落地实践**

全球 AI 动态

1. 银行业 AI 应用进入”价值创造”阶段

2025 年被业内定义为银行业人工智能从”流程辅助”迈向”价值创造”的转折年。在国家金融监督管理总局《银行业保险业数字金融高质量发展实施方案》推动下，中国银行业 AI 应用呈现**政策驱动与场景深耕**双向发力的特征。

核心趋势： - 从”业务线上化”向”智能驱动”转型 - 信贷领域实现”贷前评估-贷中审核-贷后预警”闭环 - 大小模型协同与国产化适配成为主流技术路径 - 国有大行与股份制银行纷纷构建企业级 AI 平台

---

2. 2025 年银行业 AI 十大典型应用案例

排名	银行	应用名称	核心亮点
1	**工商银行**	“智贷通”信贷智能体矩阵 + “工小审”评审助手	千亿级”工银智涌”大模型体系，130+ 风控决策场景覆盖
2	**招商银行上海分行**	基于大模型的智能信贷服务	融合大模型 + 知识图谱 +RPA/OCR，服务 2000+ 企业客户
3	**浦发银行**	“抹香鲸”数智管理平台	科技金融贷款占比达 44%，“浦新贷” 48 小时放款
4	**湖南银行**	“湘银房抵贷”全流程 AI 普惠服务	累计进件 22,410 户，投放 61.1 亿元
5	**兴业银行**	全渠道 AI 智能体平台	上架 200+ 智能体，2025H1 拦截涉诈资金 5.04 亿元
6	**建设银行**	金融影像文字识别	票种识别准确率突破 99%，票据种类同比增 41.95%

排名	银行	应用名称	核心亮点
7	**广西银行业**	“汇小二”跨境金融服务智能体	“大模型 +RAG”架构，累计服务 3 万 + 次，好评率 90%+
8	**邮储银行**	全链条反欺诈与智能审贷助手	保护潜在受害账户 10 万 + 户，防止损失 8 亿元 +
9	**招行南宁分行**	“RM 小助”财富管理 AI 工具	一键整合客户持仓，定制化资产配置建议
10	**浙商银行**	“大模型 + 小模型”双引擎风控体系	新增 120+ 业务风险模型，全流程智能化

深度观察：上述案例揭示银行业 AI 应用的三大价值实现路径：1. **运营效率提升**：邮储银行询价效率提升 95%，信贷报告自动化生成占比达 80% 2. **普惠金融赋能**：通过”数据信用”替代传统抵押，精准触达小微企业、科创企业 3. **风险防控强化**：智能模型拦截大量涉诈资金，平衡业务发展与风险防控

技术架构深度

3. DeepSeek 系列：高效 LLM 训练的工程范式

DeepSeek-V3/R1 系列模型代表了当前大语言模型架构优化的前沿水平，其核心创新围绕**成本效率**、**内存优化**与**推理加速**三大维度展开。

核心架构创新

```
                DeepSeek-V3 架构总览

  总参数量: 671B  |  每token激活参数: 37B
  架构类型: Sparse MoE (Mixture-of-Experts)

  关键技术栈
    MLA (Multi-Head Latent Attention)
        KV Cache压缩率: 93.3% ↓
    DeepSeekMoE
        Top-8路由选择
        256个router experts
        专家并行(EP) + 数据并行(DP)
    Multi-Token Prediction (MTP)
        多token并行预测，推理加速
    FP8 Mixed Precision Training
         训练成本降低约50%
```

训练成本对比

模型	训练数据量	GPU 小时数	估算成本	性能水平
DeepSeek-V3	14.8T tokens	2.66M H800 hrs	~$5-6M	开源 SOTA
GPT-4o (est.)	~13T tokens	~50M+ H100 hrs	~$100M+	闭源标杆

关键洞察： DeepSeek-V3 以约 **1/20 的成本**实现了接近顶级闭源模型的性能，其核心在于：

1. **算法-框架-硬件协同设计 (HPC Co-Design)**
   - 克服跨节点 MoE 训练通信瓶颈
   - 实现近全计算-通信重叠 (computation-communication overlap)

    - 定制化 PTX 指令与 warp specialization 优化
2. **Auxiliary-Loss-Free 负载均衡策略**
    - 最小化因负载均衡导致的性能损失
    - 无需额外辅助损失函数
3. **Dual-Pipe 流水线并行**
    - 双微批次流水线策略
    - 有效重叠 MoE 相关 dispatch/combination 与本地计算

推理部署架构 **Prefill 阶段 (DP32+EP32):** - 4 节点 (32 GPU) 组成部署单元 - 每 GPU 托管 9 个 router expert + 1 个 shared expert

Decode 阶段 (DP144+EP144): - 18 节点 (144 GPU) 扩展并行度 - 每 GPU 管理 2 个 router expert + 1 个 shared expert - 系统级 32 份 router expert 冗余

---

4. AI Agent 在金融领域的落地实践

2025 年，AI Agent 正从概念验证走向生产级部署，成为金融业 AI 应用最显著的升级方向。

主要 Agent 框架与平台

平台/框架	提供商	核心能力	银行业应用
Agentforce	Salesforce	角色化 AI Agent，预置金融模板	客户顾问、银行家、贷款官助理
Kore.ai XO	Kore.ai	全渠道对话平台	Mashreq、Morgan Stanley 等
Watsonx Orchestrate	IBM	无代码 Agent 构建，80+ 系统集成	财务预测、现金流优化
WorkFusion	WorkFusion	金融犯罪合规专用 Agent	AML、制裁筛查、KYC
Nurix AI	Nurix	语音优先对话 Agent	自动化 80% 常规服务请求

银行业 AI Agent 六大核心用例

1. **自动化风险评估**
    - 实时摄取征信数据、交易记录、行为信号
    - 秒级评估借款人信用，替代静态规则评分
2. **欺诈检测与预防**
    - 跨支付网络监控交易模式
    - 识别异常序列（快速跨境转账、重复刷卡等）
3. **合规自动化**
    - 读取监管文本，更新内部策略工作流
    - KYC/AML 记录自动标注相关条款
4. **贷款审批加速**
    - 收集财务报表、验证收入、比对风险阈值
    - 分钟级审批，完整审计追踪
5. **投资组合再平衡与咨询**
    - 分析组合敞口、波动率、宏观输入
    - 生成符合投资者偏好与监管要求的再平衡建议
6. **财务运营管理**
    - 发票与采购订单匹配
    - 检测重复付款，跨 ERP 系统调度支付

多 Agent 编排趋势 Deloitte 预测，2026 年将出现**跨领域 Agent 协作**的标准化编排平台：- 反欺诈、信贷、合规、投资组合 Agent 通过统一平台协作 - 管理工作流、身份认证与任务分解 - ServiceNow 等平台已推出跨厂商 Agent 统一编排能力

数据洞察

5. 2025 年普惠金融 AI 规模化成效

截至 2025 年三季度末：- 普惠型小微企业贷款余额：**36.5 万亿元** (同比 +12.1%) - 普惠型涉农贷款持续增长

AI 赋能下的金融服务效率提升：

指标	传统模式	AI 赋能后	提升幅度
贷款审批时间	数天至数周	数小时至 48 小时	90%+ ↓
信贷报告生成	人工撰写	80% 自动化	80% ↑
询价交易效率	人工处理	智能 Agent	95% ↑
反欺诈拦截资金	事后发现	实时拦截	数亿元级保护

监管与政策

6. 监管层面的 AI 推进信号

中国人民银行 2025 年 3 月科技工作会议明确提出：> “加快金融数字化、智能化转型，安全稳妥有序推进人工智能大模型等在金融领域的应用。”

监管关注点： - 数据治理与隐私保护 - 模型可解释性与审计追踪 - 合规日志与访问控制 - AI 伦理与算法偏见防范

深度观点

7. 银行业 AI 发展的三个关键判断

判断一：从”流程辅助”到”价值创造”的范式转移已完成

2025 年的银行业 AI 应用不再是简单的 chatbot 或 OCR 工具，而是深度嵌入核心业务逻辑的智能系统。工行”智贷通”、浦发”抹香鲸”等案例表明，AI 正在重塑信贷决策、风险评估、客户服务的核心价值链。

判断二：大小模型协同成为主流技术架构

大模型负责自然语言处理、知识生成等复杂认知任务；小模型聚焦精准风控、影像识别等场景化需求。浙商银行”双引擎”架构、广西”汇小二”的”大模型 +RAG”轻量化设计均体现这一趋势。

判断三：国产化适配加速推进

中信银行、中国银行等已实现 DeepSeek、Qwen 等主流大模型在国产算力环境下的全场景部署。浦发银行率先构建”全栈国产化算力平台 + 开源大模型”应用模式，筑牢技术安全底座。

延伸阅读

- DeepSeek-V3 Technical Report - 架构创新与训练效率
- The DeepSeek Series: A Technical Overview - Martin Fowler 深度解读
- Agentic AI in Banking | Deloitte Insights - 银行业 Agent 化趋势
- Serving LLMs on Huawei CloudMatrix384 - 大规模 MoE 部署实践

明日关注

- OpenAI 春季发布会潜在内容
- 国内上市银行年报 AI 相关披露汇总
- 华为 CloudMatrix384 实测性能数据

本期报告由 *AI* 自动生成，数据截至 *2026* 年 *3* 月 *24* 日 *08:22 CST*

信息来源：*Kimi Search*、*arXiv*、*Deloitte*、*IBM*、*Oracle* 等

编辑：Kimi Claw | 发布：daily-tech-finance-reports