每日全球情报解读

2026年4月6日

每日全球情报解读 | 2026年4月6日

一、今日主线：中国AI模型密集发布——DeepSeek V4、Qwen 3.6、腾讯Hunyuan 3.0三箭齐发

发生了什么（确认事实）

时间线： - **2026年4月4日**：阿里巴巴发布Qwen 3.6-Plus Preview，1M token上下文，免费公测 - **2026年4月3日**：Qwen 3.5 Medium系列评测发布，9B模型以7倍更小体积媲美120B模型 - **2026年4月3日**：腾讯加速AI Agent布局，WorkBuddy企业版、QClaw微信集成、OpenClaw产品套件齐发 - **2026年4月2日**：Qwen 3.6-Plus正式上线OpenRouter，号称比Claude Opus 4.6快3倍 - **2026年4月1日**：DeepSeek V4、腾讯Hunyuan 3.0预计4月发布，中国AI进入”模型军备竞赛”高潮

关键数据对比（2026年4月中国AI模型矩阵）：

实验室	旗舰模型	关键特性	定价优势
DeepSeek	V4（4月发布）	1M上下文、多模态、MoE架构	开源/成本仅为西方5-10%
阿里巴巴	Qwen 3.6-Plus	1M上下文、65K输出、始终开启CoT	**当前免费公测**
阿里巴巴	Qwen 3.5-9B	7x更小体积，性能匹敌120B模型	本地运行
Moonshot	Kimi K2.5	1T参数、Swarm Mode支持100子智能体	开源
智谱AI	GLM-5	华为昇腾训练、基准测试领先	开源
腾讯	Hunyuan 3.0	场景驱动、WeChat生态深度集成	企业级定价
字节跳动	Doubao 2.0	500x token增长、消费级应用	免费+增值

二、Latent Space AINews深度解读：中国AI模型已定义前沿

核心观点

根据**Latent Space**最新分析，进入2026年4月，中国AI实验室已从”追赶者”转变为”定义者”：

> *“DeepSeek R1引发的全球科技股抛售一年之后，中国AI生态系统不仅没有放缓，反而加速了。在特定领域——开源权重发布、智能体编排、成本效率和多模态能力——中国实验室正在设定行业节奏。”*

五大关键突破

1. DeepSeek V4：最受期待的开源模型 - 1M token上下文窗口 - 原生多模态能力 - MoE架构效率优化 - 完全运行在华为昇腾芯片上

2. Qwen 3.5：阿里巴巴开源利器 - 定价仅$0.38/百万token - 3.5-9B模型：7倍更小体积，性能超越GPT-OSS-120B - 3.5-27B-A3B：24GB RAM本地运行

3. Kimi K2.5：西方实验室外最强开源模型 - 1T参数规模 - Swarm Mode支持100个子智能体并行 - Terminal-Bench 75.1%表现

4. GLM-5：华为昇腾训练的基准领袖 - 完全基于国产芯片训练 - 在多项基准测试中领先 - 证明中国AI产业链自主化可行性

5. Doubao 2.0：字节跳动消费级巨头 - 500倍token增长 - 14亿月活用户基础（通过抖音/微信） - 端到端产品闭环

定价革命：成本仅为西方5-10%

模型	输入成本/百万token	输出成本/百万token	相比GPT-4节省
DeepSeek V4	$0.14-0.27	$0.40-1.12	**90%**
Qwen 3.5	$0.38	~$1.00	**85%**
Qwen 3.6-Plus	免费（公测期）	免费	**100%**
GPT-4	$2.50	$15.00	-
Claude Opus 4.6	$3.00	$15.00	-

三、阿里巴巴Qwen 3.6-Plus Preview发布：1M上下文免费开放

核心技术参数

2026年4月2日，阿里巴巴通过OpenRouter发布Qwen 3.6-Plus Preview：

特性	规格
上下文窗口	1,000,000 token（约2000页文本）
最大输出	65,536 token
推理模式	始终开启CoT（Chain-of-Thought）
函数调用	原生支持
当前定价	**完全免费**（公测期）

性能对标

根据社区早期测试： - **速度**：比Claude Opus 4.6快**2-3倍** - **Terminal-Bench 2.0**：61.6分 vs Claude Opus 4.5的59.3分 - **代码能力**：与GPT-5.4、Claude Sonnet 4.6相当

应用场景

- 仓库级代码分析
- 多 hour 文档处理
- 复杂多轮智能体工作流（无需分块或检索）

四、腾讯AI Agent战略全面提速：从观望者到主动出击

产品矩阵发布

2026年3月，腾讯密集发布AI Agent相关产品：

产品	发布时间	定位	核心功能
WorkBuddy	3月初	企业级	企业工作流自动化
QClaw	3月9日	微信生态	WeChat内置OpenClaw任务工具
OpenClaw产品套件	3月中	开发者/企业	多平台智能体集成

战略转型逻辑

CEO马化腾在3月18日财报会上表示： > “OpenClaw让我们能够利用腾讯的生态系统，这与功能有限的聊天机器人不同。”

AI智能体 vs 聊天机器人的本质区别： - **聊天机器人**：信息检索、对话交互 - **AI智能体**：跨应用执行任务（管理电子表格、自动化工作流）

核心优势：微信生态

- **14亿月活用户**：全球最大的单一应用用户基础
- **超级入口**：消息、支付、服务、小程序一体化
- **天然场景**：社交+商业+支付的完整闭环

人才战略

2025年12月，腾讯任命**姚顺宇**（Shunyu Yao）为首席AI科学家： - 前OpenAI研究员 - 清华姚班毕业 - ReAct和Tree of Thoughts框架贡献者 - 主张”场景驱动”而非”基准优化”

五、Agentic AI进军银行业：2026年4月15日行业峰会前瞻

即将举行的行业活动

Agentic AI in Banking 网络研讨会 - **时间**：2026年4月15日 - **主办方**：Fintech Futures - **核心议题**： - AI智能体如何实现实时客户支持 - 风险管理与反欺诈的AI应用 - 后台流程自动化与成本削减 - 伦理挑战与合规要求

Agentic AI在银行业的关键应用

应用场景	当前能力	商业价值
贷款审批	<200ms决策时间	处理时间从天缩短到分钟
反欺诈	<50ms拦截可疑交易	40-60%欺诈损失降低
KYC/AML	AI驱动的文档验证	合规成本降低35%
客户服务	60-80%查询无需人工	客服成本降低
智能投顾	自动化组合再平衡	AUM增长

麦肯锡预测

- AI可为全球银行业增加**2000-3400亿美元**年价值
- 大规模部署AI的银行报告**20-35%**自动化功能成本降低

六、字节跳动Seedance 2.0：AI视频生成进入”多镜头叙事”时代

核心创新

2026年2月8日，字节跳动发布Seedance 2.0：

特性	Seedance 2.0	Sora 2	Veo 3.1
最大分辨率	**2K**	1080p	4K
最大时长	15秒	20秒	8秒
多模态输入	**文本+图像+视频+音频**	文本+图像	文本+图像
多镜头叙事	**支持**	有限	不支持
参考视频	**支持（镜头+动作）**	不支持	不支持
水印	**无**	可见水印	SynthID元数据
自动音效	**内置**	无	SynthID音频

市场反应

发布当天，中国AI概念股大涨： - **中文在线**：20%涨停 - **上海电影**：+10% - **完美世界**：+10% - **华策影视**：+7% - **沪深300指数**：+1.63%

技术亮点

多镜头叙事（Multi-Lens Storytelling）： - 生成多个场景同时保持风格一致性 - 支持角色连续性 - 从孤立视觉片段向可用叙事内容跨越

参考能力： - 提取参考视频的镜头运动 - 替换角色 - 无缝延伸现有片段

七、中国AI芯片自主化：字节跳动35万片自研芯片计划

核心信息

2026年2月，字节跳动宣布与三星合作： - **自研AI推理芯片** - **2026年产量目标**：10万-35万片 - **工程样品**：预计2026年3月

五大关键动因

1. **出口管制**：美国限制Nvidia H100/H200对华出口

2. **成本优化**：定制ASIC推理成本更低
3. **供应安全**：减少对单一供应商依赖
4. **生态闭环**：构建完整自主产业链
5. **长期竞争**：与阿里巴巴平头哥、华为昇腾形成协同

行业趋势

中国科技巨头芯片策略： | 公司 | 策略 | 进展 | |——|——|——| | **字节跳动** | 自研+三星代工 | 2026年3月样品 | | **阿里巴巴** | 平头哥自研 | 已量产 | | **华为** | 昇腾全栈 | 支持DeepSeek V4 | | **腾讯** | 小规模采购+测试国产 | 2026年加大投资 | | **百度** | 昆仑芯 | 持续迭代 |

八、2026年4月AI模型选型决策更新

中国模型 vs 西方模型

维度	中国模型（Qwen/DeepSeek/Kimi）	西方模型（GPT/Claude/Gemini）
性能	已匹敌或超越（特定基准）	基准领先但差距缩小
成本	仅为5-10%	基准定价
开源	主流模型开源	闭源为主
上下文	1M token（Qwen/DeepSeek）	200K-1M不等
数据主权	中国境内合规	需评估GDPR/HIPAA
芯片依赖	华为昇腾可选	Nvidia CUDA生态

选型建议

选择中国模型如果： - 成本敏感（预算为西方模型10-20%） - 需要开源权重（本地部署、无供应商锁定） - 数据需要在中国境内处理 - 需要超长上下文（1M token）

选择西方模型如果： - 生态系统广度优先（插件、集成） - 多模态能力要求高 - 合规要求指向特定供应商 - 需要成熟的开发者工具链

九、今日关键阈值监测表

监测指标	当前值	阈值	状态
中国模型成本优势	西方模型5-10%	<10%	□ 健康
Qwen 3.6-Plus公测	□ 免费	开放	□ 进行中
DeepSeek V4发布	预计4月	官方确认	□ 即将
腾讯Hunyuan 3.0	预计4月	姚顺宇主导	□ 即将
字节跳动自研芯片	35万片计划	2026年量产	□ 进行中
Agentic AI银行峰会	4月15日	倒计时	□ 即将
Seedance 2.0可用性	中国内测	全球发布	□ 区域限定

十、今日金句

> *“中国实验室已从追赶者转变为定义者——在开源权重、智能体编排、成本效率和多模态能力领域设定行业节奏。” —— Latent Space AINews, 2026年4月*

> *“DeepSeek V4是测试。如果它兑现架构声明和基准目标，将是自DeepSeek R1以来最具颠覆性的开源AI发布。” —— 2026年4月行业观察*

> *“Qwen 3.6-Plus的1M上下文免费开放，标志着长文本AI进入无门槛时代。” —— 2026年4月2日*

> *“腾讯的AI转型是防御性的也是进攻性的——防御性地追赶阿里字节，进攻性地将AI转化为平台功能。” —— 2026年4月3日*

> *“2026年AI的决胜问题不再是’模型有多好’，而是’你拥有什么工作流’。” —— Agentic AI趋势观察*

十一、数据来源

- **Latent Space AINews** — 中国AI模型深度分析
- **Kimi Search** — AI行业动态与融资信息
- **OpenRouter** — Qwen 3.6-Plus发布信息
- **Caixin Global** — 腾讯AI战略报道
- **Fintech Futures** — Agentic AI银行业应用
- **AsianFin** — 字节跳动/阿里巴巴模型发布
- **Serenities AI** — Seedance 2.0技术评测
- **TechOvedas** — 字节跳动自研芯片计划
- **RenovateQR** — 中国AI模型全景分析
- **Modelfit** — Qwen 3.5系列评测
- **BuildFastWithAI** — Qwen 3.6 Plus技术解析

报告生成时间：2026年4月6日 06:30 CST 数据来源：Latent Space AINews、Kimi Search、各大AI实验室官方披露